TUGAS 3: PROJECT BASED LEARNING

PENERAPAN DAN ANALISIS KINERJA ALGORITME NAÏVE BAYES BERBASIS DATASET PUBLIK UNTUK KLASIFIKASI DATA

Disusun Oleh (Kelompok 3):

Millatina Zahra Arrumaisha	(M0523000)
Nauwadia Tri Agesi	(M0523000)
Rahma Ma'shumah Ahmad	(M0523000)
Ramadhan Imanur Rochim	(M0523000)
Thalita Anindya Ramadani	(M0523000)

Dosen Pengampu:

Prof. Dr. Dewi Retno Sari Saputro, S.Si., M.Kom.

PROGRAM STUDI S-1 MATEMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS SEBELAS MARET

SURAKARTA

2026

DAFTAR ISI

DAFTAR ISI **1**

1 PENDAHULUAN **1**

1.1 Latar Belakang Masalah 1

1.2 Perumusan Masalah 1

1.3 Batasan Masalah 1

1.4 Tujuan Penelitian 2

1.5 Manfaat Penelitian 2

2 LANDASAN TEORI **2**

2.1 Paradigma Pembelajaran Mesin Terawasi 2

2.2 Teorema Bayes dan Inferensi Probabilistik 3

2.3 Prinsip Kerja Naïve Bayes dan Aturan MAP 3

2.4 Varian Algoritme Naïve Bayes 4

2.5 Penanganan Frekuensi Nol dan Laplace Smoothing 4

2.6 Metrik Evaluasi Kinerja Klasifikasi 4

3 METODOLOGI PENELITIAN **5**

3.1 Sumber dan Deskripsi Dataset Publik 5

3.2 Alur Kerja Eksperimen 5

3.3 Pra-pemrosesan Data dan Rekayasa Fitur 5

3.4 Strategi Partisi Data 5

3.5 Implementasi Pemodelan Komputasi 6

4 HASIL DAN PEMBAHASAN **6**

4.1 Eksplorasi Data dan Karakteristik Fitur 6

4.2 Hasil Pelatihan Model dan Parameter Peluang 6

4.3 Evaluasi Kinerja Model Berdasarkan Matriks Konfusi 6

4.4 Analisis Galat Klasifikasi 6

4.5 Analisis Kritis Asumsi Independensi Bersyarat 6

4.6 Implikasi Praktis dan Komparasi Literatur 7

5 PENUTUP **7**

5.1 Simpulan 7

5.2 Saran 7

DAFTAR RUJUKAN **7**

I. PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan teknologi komputasi dan kecerdasan buatan telah mendorong pemanfaatan pembelajaran mesin (*machine learning*) dalam memecahkan berbagai permasalahan klasifikasi di dunia nyata. Dalam klasifikasi terawasi (*supervised classification*), model dilatih menggunakan himpunan data historis berlabel dengan tujuan memetakan masukan fitur ke dalam kelas diskrit yang tepat.

Salah satu algoritme pembelajaran mesin dasar yang memiliki landasan teoretis kuat adalah Naïve Bayes. Algoritme ini berakar pada Teorema Bayes dengan menerapkan asumsi independensi bersyarat antarfitur pengamatan (*conditional independence assumption*). Meskipun asumsi independensi ini tergolong sangat sederhana (*naïve*) dan jarang terpenuhi secara sempurna dalam data empiris, Naïve Bayes terbukti menghasilkan kinerja klasifikasi yang kompetitif, tangguh, serta memiliki efisiensi komputasi yang tinggi.

Untuk membuktikan keandalan dan karakteristik model ini, diperlukan pengujian langsung pada dataset publik riil yang diakuisisi dari repositori ilmiah kredibel, seperti Kaggle atau Harvard Dataverse. Makalah proyek ini menyajikan implementasi algoritme Naïve Bayes pada dataset publik tersebut, diikuti dengan evaluasi kinerja berbasis matriks konfusi dan analisis kritis terhadap pengaruh korelasi fitur pada ketepatan prediksi model.

1.2 Perumusan Masalah

Berdasarkan latar belakang tersebut, perumusan masalah dalam proyek ini dirumuskan sebagai berikut.

1. Bagaimana karakteristik sebaran dan korelasi antarfitur pada dataset publik yang digunakan?
2. Bagaimana penurunan formulasi matematis dan penerapan algoritme Naïve Bayes dalam memodelkan data tersebut?
3. Bagaimana kinerja klasifikasi Naïve Bayes yang diukur berdasarkan matriks konfusi, Akurasi, Presisi, *Recall*, dan *F1-Score*?
4. Bagaimana pengaruh pelanggaran asumsi independensi bersyarat terhadap timbulnya galat klasifikasi pada data riil?

1.3 Batasan Masalah

Ruang lingkup penulisan dan eksperimen pada proyek ini dibatasi oleh ketentuan berikut.

1. Algoritme klasifikasi yang diteliti difokuskan pada keluarga algoritme Naïve Bayes.
2. Dataset yang digunakan merupakan dataset publik riil bertipe tabular dengan label kelas acuan (*ground truth*) yang bersumber dari repositori Kaggle atau Harvard Dataverse.
3. Implementasi komputasi dilakukan menggunakan bahasa pemrograman Python dengan pustaka ilmiah standar.

1.4 Tujuan Penelitian

Tujuan pelaksanaan proyek ini dirinci ke dalam beberapa poin berikut.

1. Menerapkan algoritme pembelajaran mesin dasar Naïve Bayes pada dataset publik riil dari repositori terbuka.
2. Mengestimasi parameter distribusi probabilitas prior dan fungsi likelihood secara empiris dari himpunan data latih.
3. Mengevaluasi performa model klasifikasi secara kuantitatif menggunakan matriks konfusi dan metrik-metrik evaluasi standar.
4. Menganalisis secara kritis keterbatasan asumsi independensi fitur dan penyebab terjadinya misklasifikasi pada data uji.

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari proyek ini mencakup aspek teoretis dan aspek praktis.

1. **Manfaat Teoretis**: Memberikan pemahaman komprehensif mengenai cara kerja inferensi Bayes, komputasi posterior, dan konsekuensi matematis dari asumsi independensi bersyarat pada data empiris.
2. **Manfaat Praktis**: Menyediakan alur kerja komputasi yang terstruktur dan dapat direproduksi untuk menganalisis data publik menggunakan metode klasifikasi probabilistik.

II. LANDASAN TEORI

2.1 Paradigma Pembelajaran Mesin Terawasi

Pembelajaran mesin terawasi (*supervised learning*) merupakan kerangka pemodelan di mana algoritme mempelajari fungsi pemetaan dari ruang masukan ke ruang target berdasarkan pasangan data latih berlabel,

$$\mathscr{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}, \tag{2.1}$$

dengan $\mathbf{x}_i \in \mathbb{R}^d$ menyatakan vektor fitur berdimensi d dan $y_i \in \mathscr{C} = \{c_1, c_2, \ldots, c_K\}$ menyatakan kelas target diskrit. Tujuan utama dari proses ini adalah menemukan fungsi hipotesis $f : \mathscr{X} \to \mathscr{Y}$ yang memiliki kemampuan generalisasi optimal terhadap data baru yang belum pernah diamati sebelumnya.

2.2 Teorema Bayes dan Inferensi Probabilistik

Teorema Bayes menyatakan hubungan antara probabilitas bersyarat dan probabilitas marginal dari dua kejadian acak. Diberikan vektor pengamatan $\mathbf{x} = (x_1, x_2, \ldots, x_d)$ dan hipotesis kelas c_k, formula Teorema Bayes dinyatakan pada Persamaan (2.2),

$$P(c_k \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid c_k)P(c_k)}{P(\mathbf{x})}, \tag{2.2}$$

dengan $P(c_k \mid \mathbf{x})$ menyatakan probabilitas posterior, $P(c_k)$ menyatakan probabilitas prior dari kelas c_k, $P(\mathbf{x} \mid c_k)$ menyatakan fungsi kemungkinan (*likelihood*), dan penyebut $P(\mathbf{x})$ merupakan faktor normalisasi atau bukti (*evidence*) yang dihitung melalui hukum probabilitas total,

$$P(\mathbf{x}) = \sum_{j=1}^{K} P(c_j)P(\mathbf{x} \mid c_j). \tag{2.3}$$

2.3 Prinsip Kerja Naïve Bayes dan Aturan MAP

Penghitungan fungsi kemungkinan gabungan $P(\mathbf{x} \mid c_k) = P(x_1, x_2, \ldots, x_d \mid c_k)$ memerlukan estimasi parameter dalam jumlah sangat besar pada ruang berdimensi tinggi. Untuk mengatasi kompleksitas tersebut, Naïve Bayes menerapkan asumsi independensi bersyarat, di mana seluruh fitur diasumsikan saling bebas jika kelas target diketahui,

$$P(\mathbf{x} \mid c_k) = \prod_{j=1}^{d} P(x_j \mid c_k). \tag{2.4}$$

Berdasarkan asumsi tersebut dan mengingat nilai $P(\mathbf{x})$ konstan untuk seluruh kelas, keputusan kelas prediksi ditentukan melalui aturan *Maximum A Posteriori* (MAP) pada Persamaan (2.5),

$$\hat{y} = \arg\max_{c_k \in \mathscr{C}} \left[P(c_k) \prod_{j=1}^{d} P(x_j \mid c_k) \right]. \tag{2.5}$$

Dalam implementasi komputasi numerik, perkalian probabilitas kecil rentan menghasilkan galat *arithmetic underflow*. Oleh karena itu, Persamaan (2.5) ditransfor-

masikan ke dalam skala logaritmik,

$$\hat{y} = \arg\max_{c_k \in \mathscr{C}} \left[\ln P(c_k) + \sum_{j=1}^{d} \ln P(x_j \mid c_k) \right]. \tag{2.6}$$

2.4 Varian Algoritme Naïve Bayes

Bentuk fungsi kemungkinan $P(x_j \mid c_k)$ bergantung pada sifat tipe data fitur.

1. **Gaussian Naïve Bayes**: Digunakan untuk fitur bernilai kontinu yang diasumsikan berdistribusi normal,

$$P(x_j \mid c_k) = \frac{1}{\sqrt{2\pi\sigma_{kj}^2}} \exp\left(-\frac{(x_j - \mu_{kj})^2}{2\sigma_{kj}^2} \right), \tag{2.7}$$

   dengan μ_{kj} dan σ_{kj}^2 masing-masing menyatakan nilai rata-rata dan variansi fitur ke-j pada kelas c_k.

2. **Multinomial Naïve Bayes**: Digunakan untuk data diskrit hitungan frekuensi, seperti frekuensi kemunculan kata pada pemrosesan teks.

3. **Bernoulli Naïve Bayes**: Digunakan untuk fitur biner bernilai nol atau satu yang merepresentasikan keberadaan suatu atribut.

2.5 Penanganan Frekuensi Nol dan Laplace Smoothing

Apabila suatu nilai fitur kategorikal belum pernah muncul bersama kelas tertentu pada data latih, estimasi probabilitas bernilai nol ($P(x_j \mid c_k) = 0$). Hal ini menyebabkan nilai posterior runtuh menjadi nol. Kendala ini dimitigasi melalui teknik *Laplace smoothing*,

$$P(x_j = v \mid c_k) = \frac{N_{kjv} + \alpha}{N_k + \alpha|V|}, \tag{2.8}$$

dengan N_{kjv} menyatakan frekuensi kemunculan nilai v pada kelas c_k, N_k menyatakan jumlah sampel kelas c_k, $|V|$ menyatakan kardinalitas nilai fitur, dan $\alpha > 0$ merupakan parameter penghalus.

2.6 Metrik Evaluasi Kinerja Klasifikasi

Kualitas prediksi model dievaluasi melalui matriks konfusi yang memetakan empat kondisi hasil klasifikasi: *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Berdasarkan matriks tersebut, metrik kuantitatif dihitung melalui Persamaan (2.9) sampai (2.12),

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{2.9}$$

$$\text{Presisi} = \frac{TP}{TP+FP}, \tag{2.10}$$

$$\text{Recall} = \frac{TP}{TP+FN}, \tag{2.11}$$

$$\text{F1-Score} = 2 \times \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}}. \tag{2.12}$$

III. METODOLOGI PENELITIAN

3.1 Sumber dan Deskripsi Dataset Publik

Penelitian ini memanfaatkan dataset publik riil yang diunduh dari repositori ilmiah terbuka (Kaggle / Harvard Dataverse). Dataset tersebut memiliki target klasifikasi berlabel dengan sejumlah fitur penjelas kontinu dan kategorikal. Struktur dataset memuat n baris data pengamatan dan d atribut prediktor yang telah diverifikasi kelayakannya untuk pemodelan klasifikasi.

3.2 Alur Kerja Eksperimen

Tahapan eksperimen dirancang secara sekuensial melalui lima langkah utama: akuisisi dataset, pra-pemrosesan data, partisi himpunan data, pelatihan model Naïve Bayes, serta pengujian dan evaluasi kinerja. Alur ini menjamin bahwa seluruh evaluasi dilakukan secara objektif pada data yang terisolasi dari proses pelatihan.

3.3 Pra-pemrosesan Data dan Rekayasa Fitur

Tahap pra-pemrosesan data mencakup langkah-langkah berikut.

1. Pembersihan data dari nilai duplikat dan penanganan nilai kosong (*missing values*).
2. Transformasi dan pengkodean fitur kategorikal ke dalam representasi numerik yang sesuai.
3. Penyelarasan skala data untuk memfasilitasi komputasi parameter statistik distribusi probabilitas.

3.4 Strategi Partisi Data

Untuk menguji kemampuan generalisasi model, dataset dibagi menjadi himpunan data latih (*training set*) dan himpunan data uji (*testing set*) dengan rasio 80:20 menggunakan teknik pembagian terstratifikasi (*stratified sampling*). Pembagian ini mempertahankan proporsi sebaran kelas target pada kedua subset data. Selain itu, pengujian diperkuat dengan validasi silang (*k-fold cross-validation*) untuk memastikan kestabilan performa model.

3.5 Implementasi Pemodelan Komputasi

Pemodelan Naïve Bayes diimplementasikan menggunakan modul komputasi Python. Algoritme mengestimasi probabilitas prior kelas berdasarkan proporsi sampel latih, menghitung parameter distribusi kemungkinan per fitur, dan menerapkan aturan MAP terlogaritma untuk mengklasifikasikan sampel pada himpunan data uji.

IV. HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data dan Karakteristik Fitur

Analisis eksplorasi data (*exploratory data analysis*) dilakukan untuk memetakan karakteristik statistik setiap fitur, meliputi nilai rata-rata, simpangan baku, serta pola persebaran data. Pemeriksaan korelasi antarfutur dilakukan untuk mengidentifikasi keberadaan multikolinearitas yang berpotensi melanggar asumsi dasar independensi bersyarat Naïve Bayes.

4.2 Hasil Pelatihan Model dan Parameter Peluang

Hasil proses pelatihan model menghasilkan nilai probabilitas prior untuk masing-masing kelas target serta vektor parameter distribusi kemungkinan per atribut. Nilai-nilai parameter ini merefleksikan karakteristik unik setiap kelas yang dipelajari algoritme dari data latih.

4.3 Evaluasi Kinerja Model Berdasarkan Matriks Konfusi

Pengujian terhadap himpunan data uji menghasilkan matriks konfusi yang merangkum ketepatan prediksi model terhadap label aktual. Berdasarkan nilai kuadran TP, TN, FP, dan FN, metrik evaluasi Akurasi, Presisi, *Recall*, dan *F1-Score* dihitung secara komprehensif untuk mengukur performa sistem.

4.4 Analisis Galat Klasifikasi

Analisis galat (*error analysis*) dilakukan dengan memeriksa secara spesifik sampel-sampel data uji yang gagal diprediksi dengan benar oleh model. Kesalahan klasifikasi umumnya dipicu oleh nilai fitur yang berada pada area tumpang tindih (*overlapping distributions*) antar-kelas atau keberadaan pencilan (*outlier*).

4.5 Analisis Kritis Asumsi Independensi Bersyarat

Meskipun asumsi independensi fitur jarang terpenuhi secara sempurna pada dataset riil, Naïve Bayes tetap mampu mempertahankan performa klasifikasi yang baik. Hal ini selaras dengan temuan literatur bahwa batas keputusan (*decision boundary*) Naïve Bayes sering kali tetap optimal meskipun nilai estimasi probabilitas marginalnya mengalami bias akibat korelasi antarfitur.

4.6 Implikasi Praktis dan Komparasi Literatur

Hasil eksperimen menunjukkan bahwa keunggulan utama Naïve Bayes terletak pada kecepatan pelatihan yang sangat tinggi dan kebutuhan memori yang minimal. Karakteristik ini menjadikannya sangat relevan untuk skenario inferensi waktu-nyata (*real-time inference*) pada sistem berskala besar di industri.

V. PENUTUP

5.1 Simpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, simpulan dari proyek ini dirumuskan sebagai berikut.

1. Algoritme Naïve Bayes berhasil diimplementasikan pada dataset publik riil dengan memanfaatkan prinsip Teorema Bayes dan estimasi parameter empiris dari data latih.

2. Penerapan asumsi independensi bersyarat terbukti menyederhanakan proses komputasi tanpa mengorbankan ketepatan batas keputusan klasifikasi secara signifikan.

3. Evaluasi performa melalui matriks konfusi memberikan gambaran menyeluruh terhadap kekuatan dan kelemahan model dalam membedakan kelas target.

4. Analisis galat membuktikan bahwa misklasifikasi terutama terjadi pada titik-titik data yang memiliki derajat tumpang tindih tinggi antar-sebaran kelas.

5.2 Saran

Untuk penelitian dan pengembangan lanjutan, beberapa saran yang dapat diajukan antara lain.

1. Menerapkan teknik reduksi dimensi seperti *Principal Component Analysis* (PCA) atau seleksi fitur untuk meminimalkan korelasi antarfitur sebelum pemodelan Naïve Bayes.

2. Menguji perbandingan performa empiris Naïve Bayes terhadap algoritme klasifikasi lain, seperti *Support Vector Machine* (SVM) atau *Random Forest*, pada dataset berskala lebih besar.

DAFTAR RUJUKAN

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York.

Goodfellow, I., Y. Bengio, dan A. Courville. (2016). *Deep Learning*. MIT Press, Cambridge.

Ling, C. X., Q. Yang, dan J. Gao. (2014). Naive Bayes Classifier. *Encyclopedia of Machine Learning*, Springer, 709–711.

Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill, New York.

Program Studi S-1 Matematika FMIPA UNS. (2024). *Pedoman Pembimbingan Tugas Akhir Mahasiswa*. Universitas Sebelas Maret, Surakarta.

Saleh, A. (2015). Implementasi Metode Klasifikasi Naïve Bayes dalam Memprediksi Besarnya Penggunaan Listrik Rumah Tangga. *Citec Journal*, 2(3), 207–217.